



YZM212 – Bayes Teoremi ile Parlaklık Analizi

İsim: Furkan Büyükyozgat

Öğrenci No: 23291050

Tarih: 19/04/2026

1. Problem Tanımı

Bu çalışmada amaç, gürültülü gözlem verileri kullanılarak bir gök cisminin gerçek parlaklığını ve gözlem belirsizliğini Bayesyen yöntemlerle tahmin etmektir. Problemden parlaklık ortalaması (μ) ve gözlem hatasını temsil eden standart sapma (σ) bilinmeyen parametrelerdir. Bu parametreler, sentetik olarak üretilen gözlem verisi üzerinden tahmin edilmiştir.

Bayesyen yaklaşımın temel avantajı, parametreleri tek bir sayı olarak değil, bir olasılık dağılımı olarak ele almasıdır. Böylece hem tahmin edilen merkezî değer hem de bu tahminin belirsizliği birlikte elde edilir. Bu ödevde posterior dağılımdan örnekleme yapmak için Markov Chain Monte Carlo (MCMC) yöntemi ve emcee kütüphanesi kullanılmıştır.

2. Veri

Veri, Normal dağılımdan sentetik olarak üretilmiştir. Gerçek parametreler şu şekildedir:

$$\mu_{\text{true}} = 150.0$$

$$\sigma_{\text{true}} = 10.0$$


$$n_{\text{obs}} = 50$$

Yani model varsayımı altında her bir gözlem

$$x_i \sim \mathcal{N}(\mu, \sigma^2)$$

şeklinde üretilmiştir. Burada (μ) gerçek parlaklığı, (σ) ise ölçüm gürültüsünü temsil etmektedir.

Üretilen veri için örnek ortalaması yaklaşık (147.75), örnek standart sapması ise yaklaşık (9.34) olarak elde edilmiştir. Örnek ortalamasının gerçek değerden bir miktar sapması beklenen bir durumdur; çünkü veri sonlu sayıda ve rastgele üretilmiştir.



Histogram grafiğinde görüldüğü üzere gözlemler yaklaşık olarak 150 civarında yoğunlaşmakta, ancak örnek ortalaması gerçek değerin biraz altında kalmaktadır. Bu durum Bayesyen tahminin de doğrudan etkilenmesine neden olmaktadır.

3. Yöntem

Bu çalışmada parametre tahmini için Bayes teoremi kullanılmıştır:

$$P(\theta | D) = \frac{P(D | \theta)P(\theta)}{P(D)}$$

Burada $(\theta = (\mu, \sigma))$ parametre vektörüdür.

$(P(\theta | D))$ posterior dağılımı,

$(P(D | \theta))$ likelihood,

$(P(\theta))$ prior dağılımıdır.

3.1. Likelihood

Gözlemlerin Normal dağılımdan geldiği varsayıldığı için likelihood fonksiyonu şu şekildedir:

$$p(D | \mu, \sigma) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

Hesaplama daha kararlı olduğu için bunun logaritmik hali kullanılmıştır:

$$\log p(D | \mu, \sigma) = \frac{1}{2} \sum_{i=1}^n \left[\left(\frac{x_i - \mu}{\sigma}\right)^2 + \log(2\pi\sigma^2) \right]$$

3.2. Prior

Parametreler için geniş ve bilgilendirici olmayan bir prior seçilmiştir:

$$0 < \mu < 300$$

$$0 < \sigma < 50$$

Bu aralığın dışında prior olasılığı sıfır kabul edilmiştir. Böylece model fiziksel olarak anlamsız olan $(\sigma \leq 0)$ durumlarını dışlamaktadır.

3.3. Posterior ve MCMC

Posterior dağılım doğrudan analitik olarak elde edilmek yerine MCMC ile örneklenmiştir. Bunun için 32 walker ve 2000 adım kullanılmış, ilk 500 adım burn-in olarak atılmıştır. Daha sonra zincirden seyretilmiş örnekler alınarak posterior özet istatistikleri hesaplanmıştır.

4. Ana Deney Sonuçları

Ana deneyde elde edilen posterior median değerleri şu şekildedir:

$$\mu_{\text{median}} \approx 147.73$$

$$\sigma_{\text{median}} \approx 9.50$$

Ayrıca yaklaşık %68 güven aralıkları şu şekilde bulunmuştur:


$$\mu \approx 147.73^{+1.33}_{-1.34}$$

$$\sigma \approx 9.50^{+1.11}_{-0.89}$$


Buna göre tablo şu şekilde doldurulabilir:

Değişken	Gerçek Değer	Tahmin Edilen (Median)	Alt Sınır (%16)	Üst Sınır (%84)	Mutlak Hata
(μ) (Parlaklık)	150.0	147.73	146.39	149.05	2.27
(σ) (Hata Payı)	10.0	9.50	8.61	10.62	0.50

Bu sonuçlar, Bayesyen modelin gerçek parametrelere oldukça yakın tahminler ürettiğini göstermektedir. Özellikle (σ) parametresindeki hata oldukça küçüktür. (μ) parametresinde yaklaşık 2.27 birimlik fark bulunmakla birlikte bu fark, veri setinin örnek ortalamasının gerçek değerden sapmış olmasından kaynaklanmaktadır.



Trace plot incelendiğinde zincirlerin ilk bölümde başlangıç değerlerinden ayrılıp daha sonra kararlı bir bölgeye oturduğu görülmektedir. Burn-in sonrasında hem (μ) hem de (σ) için örneklerin sabit bir bölge etrafında salındığı gözlenmektedir. Bu da MCMC örneklemesinin genel olarak yakınsadığını göstermektedir.



Corner plot sonucunda (μ) dağılımının 147.7 civarında, (σ) dağılımının ise 9.5 civarında yoğunlaştığı görülmektedir. Gerçek değerler grafikte referans çizgileri ile gösterilmiştir. (μ) için posterior dağılım gerçek 150 değerinin biraz solunda yoğunlaşmıştır; bunun nedeni veri örnek ortalamasının da 147.75 olmasıdır. (σ) içinse posterior dağılım 10 değerine oldukça yakındır.

5. Sonuçların Yorumu

5.1. Merkezi Eğilim ve Doğruluk Analizi

Bayesyen çıkarım yöntemi, veri setindeki gürültüye rağmen gerçek parametrelere yakın tahminler üretmiştir. (μ) için mutlak hata yaklaşık 2.27, (σ) için ise yaklaşık 0.50 bulunmuştur. Bu sonuç, modelin özellikle gözlem hatasını iyi yakaladığını göstermektedir.

Matematiksel olarak bunun nedeni, geniş prior altında posterior dağılımın büyük ölçüde likelihood tarafından belirlenmesidir. Normal modelde (μ) tahmini örnek ortalamasına yakınsar. Bu nedenle veri ortalaması 150 yerine 147.75 çıktığı için posterior median da yaklaşık 147.73 olmuştur. Yani model yanlış çalışmamış, aksine verinin sunduğu bilgiye uygun bir sonuç vermiştir.

5.2. Neden (μ) Tahmini Daha Hassastır?

Tablo incelendiğinde (μ) için güven aralığının, (σ) için olan aralığa göre daha dar olduğu görülmektedir. Bunun temel istatistiksel nedeni ortalamanın tahmininin, varyans ya da standart sapma tahminine göre daha kararlı olmasıdır.

Ortalama için belirsizlik yaklaşık olarak

$$SE(\mu) \approx \frac{\sigma}{\sqrt{n}}$$

ile azalır. Veri sayısı arttıkça ortalama tahmini hızla daha hassas hale gelir. Buna karşılık (σ) tahmini, verideki saçılımın kendisine dayandığı için daha değişkendir ve özellikle sonlu örnekleme daha fazla belirsizlik taşır. Bu nedenle (μ) için posterior daha dar, (σ) için posterior daha geniş çıkmıştır.


5.3. Olasılıksal Korelasyon Analizi

Corner plot'taki ortak dağılım grafiğinde (μ) ve (σ) arasında çok güçlü bir eğik elips görülmemektedir. Dağılım hafif eğimli olsa da belirgin bir korelasyon yapısı yoktur. Bu, iki parametrenin büyük ölçüde zayıf bağımlı olduğunu göstermektedir.

Sözel olarak bu şu anlama gelir: parlaklığın ortalama düzeyi ile gözlem gürültüsü bir miktar birlikte değişebilse de biri kesin olarak arttığında diğ erinin de güçlü biçimde artması ya da azalması gibi net bir ilişki gözlenmemektedir.

6. Prior Etkisi Analizi

Bu bölümde (μ) parametresi için dar ve yanlış yönlendirici bir prior seçilmiştir. Özellikle (μ) için prior aralığı gerçek değerden çok uzak olacak şekilde 100–110 arasında sınırlandırılmıştır. Böylece prior bilgisinin posterior üzerindeki etkisi incelenmiştir.



Grafik incelendiğinde geniş prior altında (μ) posteriorunun yaklaşık 147–149 aralığında yoğunlaştığı, dar prior altında ise 109 civarına sıkıştığı görülmektedir. Aynı zamanda (σ) posteriorunun da yaklaşık 40 civarına kaydığı gözlenmektedir.

Bu durum Bayesyen yaklaşımın önemli bir özelliğini ortaya koymaktadır. Posterior dağılım

$$p(\mu, \sigma | D) \propto p(D | \mu, \sigma), p(\mu, \sigma)$$


şeklinde tanımlandığı için prior, posterior üzerinde doğrudan etkilidir. Eğer prior, gerçek değerden çok uzak ve aşırı dar seçilirse, veri posterioru düzeltmekte yetersiz kalabilir.

Bu deneyde de model, (μ) 'yu gerçek değere yaklaştıramadığı için veriyi açıklayabilmek amacıyla (σ) 'yı yapay olarak büyötmüştür. Yani yanlış prior seçimi hem parlaklık tahminini bozmuş hem de hata tahminini gereksiz şekilde artırmıştır.

Bu sonuç, prior bilgisinin dikkatli seçilmesi gerektiğini açık biçimde göstermektedir.

7. Veri Miktarının Etkisi

Bu bölümde gözlem sayısı 50'den 5'e düşürölerek veri miktarının posterior üzerindeki etkisi incelenmiştir.




Karşılaştırma grafikleri incelendiğinde (n=5) durumunda hem (μ) hem de (σ) posteriorlarının belirgin biçimde genişlediği görölmektedir. Yani parametre tahminindeki belirsizlik önemli ölçüde artmıştır.

Bu durum teorik olarak da beklenir. Ortalama için hata büyüklüğü yaklaşık olarak

$$SE(\mu) \approx \frac{\sigma}{\sqrt{n}}$$

ile değişir. Dolayısıyla (n) azaldıkça belirsizlik büyür. (n=50) iken posterior dağılım daha dar ve yoğundur; (n=5) iken ise posterior daha yayvan hale gelmiştir. Bu da veri miktarının Bayesyen tahminde ne kadar kritik olduğunu göstermektedir.



(n=5) deneyine ait corner plot incelendiğinde (μ) dağılımının çok daha geniş bir alana yayıldığı ve (σ) dağılımının sağa doğru uzun kuyruk oluşturduğu görülmektedir. Bu da az veri durumunda modelin parametreleri daha düşük güvenle tahmin edebildiğini göstermektedir. Özellikle (σ) parametresi için belirsizlik artışı çok daha belirgindir.

8. Sonuç

Bu çalışmada Bayesyen çıkarım ve MCMC yöntemi kullanılarak sentetik astronomik gözlem verilerinden parlaklık ortalaması ve gözlem hatası tahmin edilmiştir. Ana deneyde bulunan sonuçlar, gerçek değerlere yakın ve istatistiksel olarak tutarlı çıkmıştır. Posterior dağılımlar, modelin hem merkezî tahmin hem de belirsizlik bilgisini başarılı biçimde sunduğunu göstermiştir.

Ayrıca yapılan ek deneyler önemli iki sonucu ortaya koymuştur. Birincisi, yanlış ve aşırı dar bir prior seçimi posterior tahminlerini ciddi biçimde bozabilmektedir. İkincisi, veri sayısı azaldığında posterior dağılım genişlemekte ve parametre tahminlerinin güvenilirliği düşmektedir.

Sonuç olarak Bayesyen yaklaşım, özellikle belirsizliğin önemli olduğu problemlerde güçlü ve açıklayıcı bir yöntemdir. Bu ödevde elde edilen bulgular hem prior bilgisinin hem de veri miktarının parametre tahminleri üzerindeki etkisini açık biçimde göstermiştir.