

1. Bölüm

Verilenler:

- Gizli durumlar: ($S=\{e,v\}$)
- Gözlemler: ($O=\{High, Low\}$)
- Başlangıç olasılığı: ($P(e)=1.0$)
- Geçiş olasılıkları:
 - ($P(e \rightarrow e) = 0.6$)
 - ($P(e \rightarrow v) = 0.4$)
 - ($P(v \rightarrow v) = 0.8$)
 - ($P(v \rightarrow e) = 0.2$)
- Emisyon olasılıkları:
 - ($P(High|e) = 0.7$)
 - ($P(Low|e) = 0.3$)
 - ($P(High|v) = 0.1$)
 - ($P(Low|v) = 0.9$)

Gözlem dizisi:

$[High, Low]$

Viterbi algoritması ile en olası durum dizisi adım adım hesaplanır.

1. adım: İlk gözlem için olasılıkların hesaplanması

İlk gözlem (High) olduğuna göre:

$$\delta_1(e) = P(e) \cdot P(High|e) = 1.0 \cdot 0.7 = 0.7$$

Başlangıçta yalnızca (e) durumu verildiği için (v) durumu için başlangıç olasılığı (0) alınır:

$$\delta_1(v) = 0 \cdot P(High|v) = 0$$

Sonuç:

- ($\delta_1(e) = 0.7$)
- ($\delta_1(v) = 0$)

2. adım: İkinci gözlem için (e) durumunda biten yolun hesaplanması

İkinci gözlem (Low) olduğuna göre, (t=2) anında (e) durumunda bitmek için iki olasılık vardır:

Yol 1: ($e \rightarrow e$)

$$\delta_1(e) \cdot P(e \rightarrow e) \cdot P(Low | e) = 0.7 \cdot 0.6 \cdot 0.3 = 0.126$$

Yol 2: ($v \rightarrow e$)

$$\delta_1(v) \cdot P(v \rightarrow e) \cdot P(Low | e) = 0 \cdot 0.2 \cdot 0.3 = 0$$

Maksimum değeri alınır:

$$\delta_2(e) = \max(0.126, 0) = 0.126$$

Bu durumda en iyi önceki durum (e)'dir.

3. adım: İkinci gözlem için (v) durumunda biten yolun hesaplanması

(t=2) anında (v) durumunda bitmek için yine iki olasılık vardır:

Yol 1: ($e \rightarrow v$)

$$\delta_1(e) \cdot P(e \rightarrow v) \cdot P(Low | v) = 0.7 \cdot 0.4 \cdot 0.9 = 0.252$$

Yol 2: ($v \rightarrow v$)

$$\delta_1(v) \cdot P(v \rightarrow v) \cdot P(Low | v) = 0 \cdot 0.8 \cdot 0.9 = 0$$

Maksimum değeri alınır:

$$\delta_2(v) = \max(0.252, 0) = 0.252$$

Bu durumda en iyi önceki durum (e)'dir.

4. adım: En olası yolun seçilmesi

Son zamanda elde edilen değerler:

- ($\delta_2(e) = 0.126$)
- ($\delta_2(v) = 0.252$)

En büyük değeri (0.252) olduğu için son durum (v) olur. Geri izleme yapıldığında bu duruma (e) durumundan gelindiği görülür.

Bu nedenle en olası durum dizisi:

$$[e, v]$$

Sonuç olarak, gözlem dizisi ($[High, Low]$) için en olası fonem dizisi (**e-v**) olarak bulunur.

3. Bölüm

1. Ses verisindeki gürültü (noise), HMM modelindeki emisyon olasılıklarını nasıl etkiler?

Gürültü, mikrofondan alınan ses sinyalini bozarak gözlemlerin gerçek ses özelliklerini tam olarak yansıtmasını engeller. HMM’de emisyon olasılıkları, bir gizli durumun hangi gözlemi üretme ihtimalini gösterir. Ancak gürültü olduğunda, örneğin normalde e durumuna ait olması beklenen bir gözlem farklı görünebilir ve model bunu yanlışlıkla v durumuna daha yakın değerlendirebilir.

Bu durum emisyon olasılıklarının ayırt ediciliğini azaltır. Yani model, hangi gözlemin hangi duruma ait olduğunu daha zor ayırır. Sonuç olarak Viterbi algoritması da en olası durum dizisini seçerken daha fazla hata yapabilir. Kısacası gürültü arttıkça modelin gözlemleri doğru durumlarla eşleştirmesi zorlaşır ve tanıma başarımı düşer.

2. Gerçek bir sistemde binlerce kelime olduğunu düşünürsek, Viterbi yerine neden daha karmaşık yapılar (Deep Learning gibi) tercih edilmeye başlanmıştır?

HMM ve Viterbi algoritması, küçük ve kontrollü problemler için oldukça yararlıdır. Ancak gerçek konuşma tanıma sistemlerinde binlerce kelime, çok farklı konuşmacılar, farklı aksanlar, konuşma hızları ve çevresel gürültüler bulunur. Bu kadar karmaşık bir yapıda her kelime veya fonem için uygun durumları ve olasılıkları tanımlamak zorlaşır.

Ayrıca HMM tabanlı yöntemler, konuşma sinyalindeki karmaşık örüntüleri temsil etmede sınırlı kalabilir. Deep learning tabanlı yöntemler ise büyük miktarda veri üzerinden doğrudan öğrenme yapabildiği için ses içindeki karmaşık ilişkileri daha iyi yakalayabilir. Bu yöntemler farklı konuşma biçimlerine ve değişken ortamlara karşı daha dayanıklıdır. Bu nedenle günümüzde gerçek ve büyük ölçekli konuşma tanıma sistemlerinde daha yüksek başarı sağladıkları için deep learning tabanlı yaklaşımlar daha çok tercih edilmektedir.