



YZM212 - MLE ile Akıllı Şehir Planlaması

İsim: Furkan Büyükyozgat

Öğrenci No: 23291050

Tarih: 15/03/2026

Bölüm 1: Teorik Çözümler

1.1 Problemin Tanımı

Bir belediyenin ulaşım departmanında veri bilimi uzmanı olarak çalıştığınızı düşünelim. Elimizde, bir ana caddeden **1 dakikada geçen araç sayısını** gösteren gözlemler bulunmaktadır. Bu tür sayma verileri için en doğal modellerden biri **Poisson dağılımıdır**.

Poisson dağılımı, belirli bir zaman aralığında meydana gelen olay sayısını modellemek için kullanılır. Bu ödevde olay, “1 dakikada geçen araç sayısı”; parametre ise bu olayın ortalama gerçekleşme sayısını temsil eden (λ) 'dır.

Poisson olasılık kütle fonksiyonu:

$$P(K = k | \lambda) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2,$$

Burada:

- (K) : rassal değişken, yani 1 dakikadaki araç sayısı
- (k) : gözlenen araç sayısı
- (λ) : Poisson parametresi, aynı zamanda beklenen değer ve varyans

Poisson dağılımı için temel özellik:

$$E[K] = \lambda, \quad Var(K) = \lambda$$

Yani bu modelde ortalama ile varyans birbirine eşittir.

1.2 Likelihood Fonksiyonunun Yazılması

Veri setimiz (n) adet bağımsız gözlemden oluşsun:

$$k_1, k_2, \dots, k_n$$

Her bir gözlemin Poisson dağılımına uyduğunu varsayarsak, ortak olasılık yani **likelihood** fonksiyonu şu olur:

$$L(\lambda) = \prod_{i=1}^n P(K = k_i | \lambda)$$

Poisson PMF yerine yazarsak:

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{k_i}}{k_i!}$$

Çarpımı açalım:

$$L(\lambda) = \left(\prod_{i=1}^n e^{-\lambda} \right) \left(\prod_{i=1}^n \lambda^{k_i} \right) \left(\prod_{i=1}^n \frac{1}{k_i!} \right)$$

Buradan:

$$L(\lambda) = e^{-n\lambda} \lambda^{\sum_{i=1}^n k_i} \prod_{i=1}^n \frac{1}{k_i!}$$

Bu, Poisson modeli için likelihood fonksiyonudur.

1.3 Log-Likelihood Fonksiyonunun Türetilmesi

Likelihood fonksiyonunun türevini almayı kolaylaştırmak için doğal logaritma alınır. Logaritma monoton artan bir fonksiyon olduğu için, likelihood'u maksimum yapan değer ile log-likelihood'u maksimum yapan değer aynıdır.

$$l(\lambda) = \log L(\lambda)$$

Yerine yazalım:

$$l(\lambda) = \log \left(e^{-n\lambda} \lambda^{\sum k_i} \prod_{i=1}^n \frac{1}{k_i!} \right)$$

Logaritma kurallarıyla:

$$l(\lambda) = \log(e^{-n\lambda}) + \log(\lambda^{\sum k_i}) + \log \left(\prod_{i=1}^n \frac{1}{k_i!} \right)$$

Ayrı ayrı sadeleştirelim:

$$l(\lambda) = -n\lambda + \left(\sum_{i=1}^n k_i \right) \log \lambda - \sum_{i=1}^n \log(k_i!)$$

Bu ifade Poisson dağılımı için log-likelihood fonksiyonudur.

1.4 ($\widehat{\lambda}_{MLE}$) Değerinin Bulunması

MLE yaklaşımında amaç, ($l(\lambda)$) fonksiyonunu maksimum yapan (λ) değerini bulmaktır.

Türev alalım:

$$\frac{dl(\lambda)}{d\lambda} = -n + \frac{\sum_{i=1}^n k_i}{\lambda}$$

Maksimum nokta için türevi sıfıra eşitleriz:

$$-n + \frac{\sum_{i=1}^n k_i}{\lambda} = 0$$

Düzenlersek:

$$\frac{\sum_{i=1}^n k_i}{\lambda} = n$$

$$\sum_{i=1}^n k_i = n$$

$$\hat{\lambda}_{MLE} = \frac{1}{n} \sum i = 1^n k_i$$

Yani sonuç olarak:

$$\widehat{\lambda}_{MLE} = \bar{k}$$

Bu çok önemli bir sonuçtur: **Poisson dağılımında MLE ile bulunan parametre, verilerin aritmetik ortalamasıdır.**

1.5 Verilen Veri Seti İçin Analitik Sonuç

Veri seti:

[12, 15, 10, 8, 14, 11, 13, 16, 9, 12, 11, 14, 10, 15]

Toplam gözlem sayısı:

$$n = 14$$

Toplam araç sayısı:

$$\sum k_i = 170$$

Dolayısıyla:

$$\widehat{\lambda}_{MLE} = \frac{170}{14} = 12.142857$$

Yaklaşık olarak:

$$\widehat{\lambda}_{MLE} \approx 12.143$$

Bu sonuç, caddeden 1 dakikada geçen araç sayısının ortalama olarak yaklaşık **12.14 araç/dakika** olduğunu gösterir.

Bölüm 2: Analiz ve Yorumlar

2.1 Sayısal MLE Sonucu

Kod içinde negatif log-likelihood fonksiyonu kullanılmış ve `scipy.optimize.minimize` yöntemiyle bu fonksiyonu minimize eden (λ) değeri bulunmuştur.

Poisson için log-likelihood:

$$l(\lambda) = -n\lambda + \left(\sum k_i\right) \log \lambda - \sum \log(k_i!)$$

Optimizasyonda ($\sum \log(k_i!)$) terimi (λ)'ya bağlı olmadığı için sabit kabul edilir ve ihmal edilebilir. Böylece minimize edilen negatif log-likelihood şu biçimde yazılmıştır:

$$NLL(\lambda) = n\lambda - \left(\sum k_i\right) \log \lambda$$

Bu fonksiyonun minimumu, log-likelihood'un maksimumuna karşılık gelir.


Kod çıktısına göre sayısal çözüm ile elde edilen değer de analitik çözümle aynıdır:

$$\widehat{\lambda}_{numerical} \approx 12.143$$

Bu beklenen bir sonuçtur. Çünkü teorik olarak Poisson MLE doğrudan örnek ortalamasına eşittir. Sayısal optimizasyon da aynı noktaya ulaşmıştır. Bu durum, yazılan kodun doğru çalıştığını gösterir.

2.2 Grafiklerin Yorumlanması: Orijinal Veri ve Poisson PMF Karşılaştırması

Orijinal veri seti için çizilen histogram ile aynı grafikte gösterilen Poisson PMF karşılaştırıldığında, modelin veri ile oldukça uyumlu olduğu görülmektedir.



Veriler esas olarak **8 ile 16** aralığında yoğunlaşmaktadır. En sık görülen değerler yaklaşık olarak **10, 11, 12, 14 ve 15** civarındadır. Poisson PMF eğrisi de en yüksek olasılığı yaklaşık ($\lambda \approx 12$) civarında vermektedir. Bu nedenle grafiksel olarak histogram ile Poisson eğrisi arasında genel şekil bakımından makul bir uyum vardır.

Burada şu sözel yorumu yapmak mümkündür:

- Veri setinin merkezi yaklaşık 12 civarındadır.
- Poisson modeli de en büyük kütleyi bu bölgeye yerleştirmektedir.
- Dağılım tek tepeli görünmektedir.
- Çok büyük veya çok küçük değerler veri setinde bulunmadığı için Poisson modeli makul bir yaklaşım sağlamaktadır.

Matematiksel açıdan bakarsak, Poisson dağılımında hem ortalama hem varyans (λ)'ya eşittir. Bu veri setinde ortalama yaklaşık 12.14 olduğundan, modelin merkezi de doğal olarak 12 civarında oluşmuştur. Histogramdaki yoğunluğun bu bölge çevresinde toplanması, Poisson varsayımını desteklemektedir.

Ancak burada önemli bir nokta da vardır: histogram yalnızca 14 gözlemden oluşan küçük bir örnekleme dayanmaktadır. Bu nedenle uyum “mükemmel” olmak zorunda değildir. Yine de gözle görülür biçimde kabul edilebilir bir eşleşme vardır.

Sonuç olarak bu bölümde şu yorum yapılabilir: Orijinal veri seti için Poisson modeli gözlemlere makul düzeyde uyum sağlamaktadır.

2.3 Outlier (Aykırı Değer) Analizi

Ödevin bu bölümünde veri setine yanlışlıkla kaydedilmiş bir **200** değerli gözlem eklenmiştir. Yeni veri seti artık şu mantığa sahiptir:

- Orijinal gözlemler yaklaşık 8–16 aralığındadır.
- Bunlara ek olarak tek bir tane **200** vardır.

Yeni toplam gözlem sayısı:

$$n = 15$$

Yeni toplam:

$$170 + 200 = 370$$

Dolayısıyla yeni MLE:


$$\widehat{\lambda}_{MLE} = \frac{370}{15} = 24.667$$

Burada kritik bir değişim vardır. Tek bir aykırı gözlem yüzünden parametre tahmini yaklaşık iki katına çıkmıştır:

$$12.143 \rightarrow 24.667$$

2.4 Outlier Sonrası Grafiğin Yorumu

Outlier sonrası çizilen histogram ve Poisson PMF grafiği, model uyumunun ciddi şekilde bozulduğunu göstermektedir.



Histogramda gözlemlerin çok büyük kısmı hâlâ 8–16 aralığında toplanmaktadır. Ancak tek bir 200 değeri, eksenin çok sağına ayrı bir sütun eklemektedir. MLE yöntemi ortalamaya dayandığı için, bu tek büyük değer ortalamayı yukarı çekmiş; buna bağlı olarak Poisson PMF eğrisinin merkezi de yaklaşık 25 civarına kaymıştır.

Bu yüzden şu durum ortaya çıkmıştır:

- Gerçek veri kitlesi 10–15 civarındadır.
- Model ise en yüksek olasılığı 24–25 civarına vermeye başlamıştır.
- Yani model artık verinin esas çoğunluğunu temsil edememektedir.

Tek bir hatalı kayıt tüm modelin merkezini bozmuştur.

Matematiksel sebep açıktır. Poisson MLE:

$$\widehat{\lambda}_{MLE} = \bar{k}$$

olduğu için, MLE doğrudan örnek ortalamasına eşittir. Aritmetik ortalama ise aykırı değerlere karşı hassastır. Eğer veri içinde çok büyük bir sayı varsa, ortalama bu sayıdan güçlü biçimde etkilenir. Bu nedenle Poisson için MLE, outlier'lara karşı robust değildir.

2.5 Gerçek Hayat Yorumu: Belediye Planlamasında Olası Hata

Bu durumun gerçek hayatta önemli sonuçları olabilir. Belediye ulaşım planlamasında bu verileri kullanarak yol genişletme, kavşak düzenleme, sinyalizasyon süresi ayarlama veya ek şerit açma gibi kararlar verebilir.

Normal durumda veri yaklaşık olarak 12 araç/dakika seviyesini göstermektedir. Ancak outlier içeren analiz, trafik yoğunluğunu yaklaşık 25 araç/dakika gibi algılamaktadır. Bu da karar vericilere sanki cadde normalden çok daha yoğunmuş gibi yanlış bir izlenim verir.

Bunun olası sonuçları şunlar olabilir:

- Gereksiz yol genişletme kararı
- Yanlış bütçe tahsisi
- Trafik sinyal sürelerinin gereksiz biçimde değiştirilmesi
- Gerçek ihtiyaç olan başka bölgelere kaynak ayrılamaması

Veri setindeki kalitesindeki tek bir hata, karar kalitesini de bozabilir. MLE güçlü ve doğal bir yöntemdir; ancak aykırı değerlere karşı hassas olabilir.

Bu sonuçtan yola çıkarak gerçek uygulamalarda yalnızca parametre tahmini yapmanın yetmediği; veri temizlemenin, aykırı değer tespiti ve ön işleme adımlarının da kritik öneme sahip olduğu ortadadır.

Sonuç

Bu çalışmada, 1 dakikada geçen araç sayısını modellemek için Poisson dağılımı kullanılmış ve parametre tahmini Maximum Likelihood Estimation yöntemiyle gerçekleştirilmiştir.

İlk olarak teorik çözüm yapılmış ve Poisson dağılımı için MLE tahmininin örnek ortalamasına eşit olduğu gösterilmiştir:

$$\widehat{\lambda}_{MLE} = \bar{k}$$

Verilen trafik verisi için bu değer:

$$\hat{\lambda} \approx 12.143$$

olarak bulunmuştur. Python ile yapılan sayısal optimizasyon da aynı sonucu vermiştir. Bu, teorik çözüm ile kod çıktısının tutarlı olduğunu göstermektedir.

Daha sonra bu parametre ile çizilen Poisson PMF grafiği, gerçek veri histogramı ile karşılaştırılmıştır. Grafik, modelin veriye makul düzeyde uyduğunu göstermiştir.

Son aşamada veri setine 200 değerli bir outlier eklenmiş ve MLE tekrar hesaplanmıştır. Yeni tahmin:

$$\hat{\lambda} \approx 24.667$$

olmuştur. Tek bir aykırı gözlemin, tahmini yaklaşık iki katına çıkardığı görülmüştür. Bu sonuç, Poisson MLE'nin ortalamaya eşit olması nedeniyle outlier'lara hassas olduğunu açıkça göstermektedir.

Genel olarak bu ödevden çıkarılan en önemli sonuç şudur:

MLE teorik olarak güçlü, uygulamada pratik ve sezgisel bir yöntemdir; ancak veri kalitesi bozulduğunda ciddi hatalara açık olabilir. Bu nedenle özellikle gerçek hayat

uygulamalarında, model kurmadan önce veri temizliği ve aykırı değer analizi mutlaka yapılmalıdır.

Kaynakça

<https://www.geeksforgeeks.org/maths/poisson-distribution/>

<https://www.geeksforgeeks.org/machine-learning/probability-density-estimation-maximum-likelihood-estimation/>